

Sistema Fintech de Préstamos Digitales para Bolivia

Software Design Document (SDD)

Parte V

Estrategia de Inteligencia Artificial y Análisis de Costos

Versión: 1.0

Tabla de Contenido

1. Objetivos
 2. Rol de la IA dentro de la plataforma
 3. Arquitectura propuesta
 4. Proveedores de IA
 5. Comparativa de modelos
 6. Estrategia para el MVP
 7. Estimación de costos
 8. Estrategia de reducción de costos
 9. Roadmap de evolución
 10. Conclusiones
-

1. Objetivos

La Inteligencia Artificial será uno de los pilares de la plataforma, pero **no debe convertirse en el principal costo operativo**.

La arquitectura deberá diseñarse para:

- minimizar costos
 - poder cambiar de proveedor fácilmente
 - utilizar el mejor modelo según cada tarea
 - evitar dependencia de un único proveedor (Vendor Lock-in)
-

2. Rol de la IA

La IA **NO aprobará préstamos automáticamente.**

La decisión final dependerá de:

- políticas de negocio
- motor de reglas
- validaciones
- analistas
- supervisor

La IA será un asistente para automatizar procesos.

Funciones de la IA

Atención al cliente

Canal:

- WhatsApp

Funciones

- responder consultas
 - registrar solicitudes
 - solicitar documentos
 - explicar requisitos
 - consultar estado
-

OCR Inteligente

Extraer información de:

- Carnet de Identidad
 - Pasaporte
 - Licencia
 - Facturas
 - Boletas
 - Extractos Bancarios
-

Evaluación

La IA podrá:

- resumir expedientes
 - detectar inconsistencias
 - identificar documentos faltantes
 - clasificar riesgo
 - recomendar acciones
-

Cobranza

Analizar:

- historial
 - comportamiento
 - mora
 - probabilidad de recuperación
-


Soporte interno

Ayudar a los analistas mediante:

- resúmenes
 - búsqueda de información
 - generación de respuestas
 - explicación de reglas
-

3. Arquitectura Recomendada

Toda comunicación con modelos de IA pasará por un único servicio.



Ventajas

- cambiar proveedor fácilmente
- comparar respuestas
- reducir costos
- balancear carga
- alta disponibilidad

4. Proveedores Evaluados

OpenAI

Ventajas

- excelente calidad
- herramientas maduras
- gran ecosistema

Desventajas

- costo relativamente alto

Anthropic Claude

Ventajas

- excelente razonamiento
- muy buena redacción

- análisis complejos

Desventajas

- costo medio-alto
-

Google Gemini

Ventajas

- buena velocidad
- costo competitivo
- contexto amplio

Desventajas

- algunas funciones aún evolucionan rápidamente
-

DeepSeek

Ventajas

- muy bajo costo
- excelente rendimiento
- gran capacidad de razonamiento

Desventajas

- ecosistema más pequeño que OpenAI
-

Qwen

Ventajas

- económico
- rápido
- buena comprensión

Ideal para

chatbots

Kimi / Moonshot

Muy interesante para documentos largos.

Podría utilizarse posteriormente.

5. Comparativa

Modelo	Calidad	Velocidad	Costo	Recomendación
GPT-5.5	★★★★★	★★★★★	Alto	Casos complejos
Claude Sonnet	★★★★★	★★★★★	Medio	Excelente analista
Gemini Flash	★★★★★	★★★★★	Bajo	Muy recomendable
DeepSeek V4 Flash	★★★★★	★★★★★	Muy bajo	MVP
DeepSeek V4 Pro	★★★★★	★★★★★	Bajo	Producción
Qwen	★★★★★	★★★★★	Muy bajo	Chatbots

6. Estrategia para el MVP

Durante la primera etapa se recomienda minimizar el gasto.

Chatbot

DeepSeek Flash

Consultas internas

DeepSeek Flash

Evaluaciones complejas

DeepSeek Pro

Resúmenes

DeepSeek Pro

OCR

Servicio especializado

No utilizar un LLM.

Embeddings

Modelo Open Source.

Resultado

Excelente relación costo-beneficio.

7. Estimación de Costos

Los siguientes valores son **estimaciones** para dimensionar el presupuesto. Los precios reales dependerán del proveedor elegido, la cantidad de tokens consumidos y los cambios de tarifas publicados por cada servicio.

Escenario 1

Startup

100 solicitudes por mes

Costo IA aproximado

Menos de USD 5/mes utilizando modelos económicos.

Escenario 2

1.000 solicitudes

Costo IA

Entre **USD 10 y USD 30/mes** dependiendo del modelo y la longitud de las conversaciones.

Escenario 3

10.000 solicitudes

Costo IA

Entre **USD 100 y USD 300/mes** usando una estrategia basada en modelos económicos.

Escenario 4

100.000 solicitudes

Costo IA

Entre **USD 1.000 y USD 3.000/mes** si la mayor parte de las conversaciones utiliza modelos de bajo costo.

Conclusión

El costo de la IA representa una pequeña fracción del costo operativo de una fintech.

Generalmente será menor que:

- WhatsApp Business
 - publicidad
 - personal
 - infraestructura
 - cobranza
-

8. Estrategia para Reducir Costos

No enviar todo al LLM

Ejemplo

Consultar saldo.

No necesita IA.

Consultar cuotas.

No necesita IA.

Consultar documentos.

No necesita IA.

Solo preguntas abiertas utilizarán IA.

Cache

Guardar respuestas frecuentes.

Respuestas híbridas

Utilizar reglas.

Solo utilizar IA cuando sea necesario.

OCR especializado

No gastar tokens leyendo documentos.

IA por niveles

Nivel 1

FAQ

↓

Reglas

Nivel 2

DeepSeek Flash

↓

Conversación

Nivel 3

DeepSeek Pro

↓

Evaluación

Nivel 4

Claude / GPT

↓

Casos excepcionales

9. Roadmap de Evolución

MVP

DeepSeek Flash

V2

DeepSeek Pro

V3

IA para cobranza

V4

Scoring IA

V5

Predicción de mora

V6

Agentes especializados

Ventas

Cobranza

Analistas

Supervisor

Auditoría

10. Recomendación Arquitectónica

Nunca depender directamente de un proveedor.

La aplicación únicamente conocerá un servicio.

AI Service

Este servicio decidirá qué modelo utilizar.

Ejemplo

Consulta simple

↓

DeepSeek Flash

Documento largo

↓

Claude

Resumen

↓

Gemini

Predicción

↓

Modelo propio

La aplicación nunca deberá saber qué proveedor respondió.

11. Costos Operativos Totales

Para una fintech pequeña, la IA **no será el mayor gasto**.

El presupuesto mensual normalmente se distribuirá así:

Concepto	Participación aproximada
Marketing y publicidad	40–60 %
Personal operativo	20–35 %
WhatsApp Business y comunicaciones	5–15 %
Infraestructura cloud	5–10 %
Inteligencia Artificial	1–5 %

Esto demuestra que invertir en IA para automatizar procesos suele ser rentable, ya que puede reducir costos de personal, acelerar la evaluación de solicitudes y mejorar la atención al cliente.

Conclusiones

La Inteligencia Artificial será un componente estratégico de la plataforma, pero debe utilizarse de forma eficiente.

Se recomienda:

- Diseñar un **AI Service** desacoplado del proveedor.
- Utilizar **DeepSeek Flash** para el chatbot y tareas rutinarias durante el MVP.
- Reservar modelos más avanzados (DeepSeek Pro, Claude o GPT) para análisis complejos y excepciones.
- Combinar IA con reglas de negocio, OCR especializado y automatización para minimizar el consumo de tokens.
- Mantener una arquitectura flexible que permita incorporar nuevos modelos en el futuro sin modificar el resto del sistema.

Con esta estrategia, la plataforma podrá ofrecer una experiencia moderna basada en IA manteniendo un costo operativo bajo y escalable.